Gerenciamento de memória¹²

1 Visão crítica geral

O uso correto da memória de computadores é requisito fundamental de sistemas bem projetados. Para isso, é importante entender alguns princípios básicos sobre gerenciamento de memória:

Overhead de utilização. O processamento de dados é efetuado na CPU, que contém memórias internas para minimizar a sobrecarga computacional (overhead) de solicitar dados a outros dispositivos (RAM, disco, etc.). No entanto, tecnologias de armazenamento de alto desempenho apresentam elevado custo, limitando a capacidade de armazenamento destes dispositivos. Assim, o gerenciamento de memória em um computador é feito de maneira hierárquica, com unidades mais velozes apresentando menor capacidade de armazenamento e vice-versa. Sistemas de alta performance devem tentar minimizar o nível de estruturas de memória envolvidas em sua execução, devendo, portanto, otimizar seu uso de memória.

Organização da memória. Aplicações escritas em C/C++ organizam o espaço de memória disponibilizado pelo sistema operacional para sua execução de maneira segmentada. Primeiro, o código da aplicação é armazenado em um sub-bloco denominado segmento de código. Em seguida, as variáveis alocadas de maneira estática são armazenadas em um sub-bloco denominado segmento de dados. O bloco formado pela união do segmento de dados com o segmento de código é denominado espaço de alocação estática.

O espaço restante é denominado espaço de alocação dinâmica, sendo reservado para alocações em tempo de execução. Este espaço é subdividido em **stack** (pilha) e **heap**, que não apresentam divisão fixa entre elas. Especificamente, a pilha é utilizada para armazenamento de contexto (variáveis de escopo), crescendo de forma significativa em procedimentos recursivos. Por sua vez, a heap é utilizada para armazenar variáveis alocadas dinamicamente por instruções da aplicação. Uma vez que crescem em direções opostas compartilhando o mesmo espaço, é possível ter estouros de pilha (stack overflow) ou de heap (heap overflow) devido a um procedimento recursivo que se expanda demasiadamente (estouro de pilha) ou a uma aplicação que solicite memória em excesso (estouro de heap).

Alocação dinâmica. A possibilidade de criar variáveis em tempo de execução ou definir espaços de armazenamento de tamanho variável oferece grande expressividade e flexibilidade aos sistemas de computação. No entanto, instruções de alocação dinâmica são processadas pelo sistema operacional, o que gera um overhead computacional a cada solicitação. Ademais, nem todas as plataformas fornecem a possibilidade de alocação dinâmica, como muitas plataformas de sistemas embarcados. Por fim, linguagens que permitem o controle de baixo-nível dos espaços de endereçamento, como C/C++, delegam uma séria responsabilidade aos programadores.

Dadas as considerações acima, a decisão entre o uso ou não de alocação dinâmica costuma variar em função do tipo de sistema que se desenvolve:

¹Roteiro de estudo fornecido na disciplina de Linguagem de Programação 1 (LP1) da Universidade Federal do Rio Grande do Norte (UFRN).

²Autor: Leonardo Bezerra (leobezerra@imd.ufrn.br).

- Sistemas embarcados em geral, deve-se evitar alocação dinâmica neste tipo de sistema. As exceções são aplicações desenvolvidas para plataformas que oferecem alocação dinâmica e não são utilizadas para processamento de informações em tempo-real.
- Sistemas tradicionais em geral, deve-se adotar alocação dinâmica neste tipo de sistema. Seu uso beneficia o sistema em diversas maneiras, sendo tolerável o *overhead* de alocação.
- Sistemas de alta performance em geral, deve-se usar a alocação dinâmica somente quando inevitável. No entanto, o correto uso de alocação estática para substituir a alocação dinâmica requer um bom nível técnico da equipe de desenvolvimento.

2 Alocação estática em C++

Tanto C como C++ fornecem dois tipos de acesso a memória quando se trabalha com alocação estática. No **acesso direto**, a variável declarada representa um espaço de memória. No **acesso indireto**, o espaço de memória é acessado através de seu endereço, que por sua vez pode ser armazenado em uma variável especial para endereços, denominada *ponteiro*. Além disso, o C++ permite que um espaço de memória seja associado a múltiplas variáveis, utilizando acesso direto através de *referências*. Por fim, tanto C como C++ permitem ambos os tipos de acesso para vetores, o que nesta disciplina será denominado **acesso misto**.

2.1 Exemplos

A seguir, alguns exemplos das diferentes possibilidades oferecidas pela linguagem C++ (os códigos estão disponíveis através dos links ou no apêndice adicionado no SIGAA):

- 1. **Acesso direto** (sem referências):
 - Variáveis escalares: http://cpp.sh/33n3i
 - Vetores: http://cpp.sh/2fkt
- 2. Acesso direto (com referências³): para declarar uma variável como referência para outra, é necessário utilizar o símbolo & logo após o tipo de dado contido na variável.
 - No mesmo escopo: http://cpp.sh/5owne
 - Como parâmetro: http://cpp.sh/7rkej
- 3. Acesso indireto (com ponteiros): para declarar uma variável como ponteiro para outra, é necessário utilizar o símbolo * logo após o tipo de dado contido na variável. Note que, como ponteiros devem armazenar apenas endereços de memória, é necessário utilizar operadores auxiliares para obter e acessar endereços. Especificamente, o operador & retorna o endereço de memória de uma variável, enquanto o operador * acessa o endereço especificado por um ponteiro⁴.
 - No mesmo escopo, com variáveis escalares: http://cpp.sh/7phkr
 - No mesmo escopo, com vetores: http://cpp.sh/8opxh
 - Como parâmetro, com variável escalar: http://cpp.sh/8eqp3
 - Como parâmetro, com vetores: http://cpp.sh/4dag5

2.2 Laboratório

Palíndromos são palavras ou frases que podem ser lidas em ambos os sentidos (ex.: ana, ovo, osso, radar, reviver, rodador)⁵. Uma possível forma de verificar se uma palavra/frase é um palíndromo é invertê-la e testar se a versão invertida é idêntica à original. Neste exercício de implementação, você deve implementar um verificador de palíndromos, restrito ao caso de palavras⁶. O código modelo está disponível no SIGAA (modelo-palindromo.zip).

³Referências também são conhecidas como *aliases*, ou apelidos, já que na prática são nomes de variáveis diferentes para endereçar um mesmo espaço de memória.

⁴Note que o léxico do C++ é confuso neste aspecto, uma vez que os símbolos * e & são utilizados tanto para denotar que uma variável é, respectivamente, um ponteiro ou uma referência, como para obter e acessar endereços. Neste último caso, o símbolo & denota o operador de referenciamento (obtenção de um endereço de memória), enquanto o símbolo * denota o operador de desreferenciamento (acesso a um endereco de memória).

⁵Da esquerda para a direita ou da direita para a esquerda.

⁶Para a verificação de frases, é necessário desconsiderar espaços e pontuações. Este será o tema de outro exercício no futuro.

3 Alocação dinâmica em C++

Quando lançado, o C++ trouxe grandes melhorias em relação ao C no que diz respeito ao gerenciamento de memória com alocação dinâmica. Mais precisamente, o C++ oferece os operadores new e delete, detalhadas abaixo:

new, new[] o operador new permite a alocação e inicialização de variáveis escalares, em substituição à função malloc do C. Para alocação de vetores, utiliza-se o operador new[]. As principais vantagens dos operadores new e new[] são a segurança de tipos e a possibilidade de inicializar tipos abstratos de dados de forma customizada.

```
int * var1 = new int;
int * v1 = new int[5];
int n = 3;
int * v2 = new int[n];
```

delete, delete[] o operador delete permite a liberação de variáveis escalares alocadas dinamicamente com o operador new. Por sua vez, o operador delete[] deve ser usado para liberar vetores alocados dinamicamente com o operador new[]. A principal vantagem dos operadores delete e delete[] é a possibilidade de liberar memória de forma customizada no caso de tipos abstratos de dados.

```
delete var1;
delete [] v1;
delete [] v2;
```

Correspondência de operadores. Uma vez que C++ ainda permite o uso das funções malloc e free, é importante entender que cada método de liberação de memória só pode ser usado para liberar um espaço alocado por seu método de alocação correspondente. Assim, uma variável alocada com new só pode ser liberada com delete. Por sua vez, vetores alocados com new[] devem ser liberados com delete[]. Por fim, qualquer espaço de memória alocado com a função malloc (ou calloc) devem ser liberados com a função free.

3.1 Exemplos

Além dos operadores new e delete, o C++ oferece uma outra forma de acesso a espaços de memória alocados dinamicamente. Além do acesso indireto a variáveis escalares e vetores, C++ também permite acesso misto a vetores, como exemplificado abaixo⁷.

- 1. Acesso indireto (com ponteiros):
 - No mesmo escopo, com variáveis escalares: http://cpp.sh/85yq3
 - No mesmo escopo, com vetores: http://cpp.sh/2c7do
 - Como parâmetro, com variável escalar: http://cpp.sh/5awj
 - Como parâmetro, com vetores: http://cpp.sh/9isn2
- 2. **Acesso misto**: aplica-se quando se deseja alocar um vetor cujo tamanho será determinado pelo conteúdo de uma variável⁸.

```
    No mesmo escopo: http://cpp.sh/9yqno
    Como parâmetro: http://cpp.sh/473qm
```

3.2 Laboratório

No exemplo do código com palíndromos, implemente uma interface com o usuário solicitando a palavra que deverá ser testada. Note que esta implementação corresponde à main do programa, devendo ser implementada no arquivo application/lab01.cpp. Além disso, o uso de alocação dinâmica neste trecho da aplicação exigirá o uso de alocação dinâmica também no arquivo source src/palindromo.cpp.

⁷É importante salientar que o acesso misto só é recomendado no caso de tipos primitivos. Seu uso com tipos abstratos de dados deve ser cauteloso, uma vez que é possível ter vazamentos de memória quando o tipo abstrato apresenta alguma variável interna alocada dinamicamente.

⁸Note que é possível usar a função **free** para liberar o espaço alocado para um vetor neste caso, mas isto não é necessário, uma vez que neste tipo de alocação o compilador já adiciona operações de liberação de memória ao término da execução do programa. No entanto, esta é uma opção que pode ser útil caso seu programa necessite de uma quantidade excessiva de memória

4 Matrizes

A alocação de matrizes em C++ ocorre de forma similar à alocação em C. De fato, a única diferença entre as duas linguagens refere-se ao uso dos operadores new [] e delete [].

4.1 Exemplos

- Alocação estática: http://cpp.sh/9ehce
- Alocação dinâmica, no mesmo escopo: http://cpp.sh/5bemn
- Alocação dinâmica, como parâmetro: http://cpp.sh/2kbe5

5 Depuração

Inevitavelmente, a possibilidade de gerenciar memória manualmente em C/C++ leva a erros por parte de programadores com pouca experiência nestas linguagens. Para auxiliar a depuração do seu código, duas ferramentas principais costumam ser utilizadas:

gdb é o depurador oficial distribuído junto a compiladores GCC. Seu uso é recomendável na análise da lógica de programação de sistemas, uma vez que permite a análise interativa do código da aplicação.

Extra! Explique o funcionamento do gdb. Especificamente, explique quais flags de compilação devem ser ativadas para que o gdb possa ser utilizado, bem como os principais comandos oferecidos pelo gdb. Por fim, demonstre seu uso em um código de aplicação concreto.

valgrind é uma coleção de ferramentas tradicionalmente utilizada para a verificação de erros relacionados à memória em uma aplicação⁹. Diferentes funcionalidades são oferecidas por este software, controladas por flags de ativação. Em geral, as flags mais utilizadas são:

- -v, que torna as mensagens do valgrind mais explícitas (mais verboso).
- --leak-check=full, que solicita ao memcheck que identifique possíveis vazamentos de memória.
- --show-reachable=yes, que inclui no diagnóstico de vazamentos de memória regiões que poderiam ser recuperada pela a aplicação.

O arquivo depuracao.zip contém exemplos dos principais tipos de erros e como o valgrind os relata. Para compilar cada exemplo, use make termo, substituindo termo por uma das opções em negrito abaixo. Para executar o valgrind, use valgrind ./termo -v --leak-check=full --show-reachable=yes.

- leak: representa os casos em que houve vazamento de memória (memory leak). Isto acontece quando o programador esquece de liberar uma região de memória alocada dinamicamente.
- **overflow**: representa os casos em que se faz um acesso ou escrita além da área alocada. um estouro de heap (heap buffer overflow). Como discutido anteriormente, isto ocorre quando se tenta alocar dinamicamente mais memória do que o permitido pelo sistema operacional.
- uninit: representa os casos em que se tenta utilizar uma variável não inicializada (unitialized).
- free: representa os casos em que se tenta liberar uma região já liberada anteriormente (double memory free).

6 Laboratório

Para finalizar este roteiro, você deverá implementar uma aplicação denominada matrizes, em um projeto de nome lab02. Sua aplicação deverá seguir o mesmo modelo de organização utilizado para trabalhos anteriores, e deverá conter três funcionalidades principais:

- 1. void print(int **, int, int); imprime uma matriz n x m.
- 2. void transpose(int **, int, int); transpõe uma matriz n x m.
- 3. int ** diagonal(int **, int, int); reduz o espaço necessário para o armazenamento de uma matriz simétrica.

⁹Esta análise é feita implicitamente pela ferramenta memcheck da coleção valgrind.